

Testy istotności statystycznej¹

1. W ramach ćwiczenia należy wykonać (w zależności od danych) odpowiedni test istotności statystycznej. Należy w pierwszej kolejności sprawdzić **spełnienie wymaganych założeń (normalność rozkładów oraz równość wariancji)** i w zależności od otrzymanych wyników wykonać właściwy test (**parametryczny** lub **nieparametryczny**). W przypadku analizy ANOVA należy, gdy są do tego przesłanki, wykonać kilka **testów post-hoc** i porównać wyniki każdego testu (które zwykle nieco różnią się od siebie wynikami szczegółowymi, choć końcowa konkluzja może być podobna).

2. Test t-Studenta dla zmiennych niepowiązanych

Przypuśćmy, że podajemy 2 leki obniżające ciśnienie dwóm różnym grupom pacjentów. Szukamy odpowiedzi na pytanie, który z tych leków jest skuteczniejszy. W tym zadaniu odpowiednie obliczenia wykonać z użyciem programu komputerowego **oraz ręcznie**. Porównać otrzymane wyniki i je zwizualizować na wykresie, gdzie zostaną zaznaczone wartości krytyczne oraz wartości otrzymane z testu t-Studenta.

Ciśnienie	Lek	Ciśnienie	Lek
5	lek A	6	lek B
6	lek A	5	lek B
12	lek A	11	lek B
9	lek A	5	lek B
8	lek A	3	lek B
5	lek A	4	lek B
7	lek A	6	lek B
8	lek A	6	lek B
15	lek A	4	lek B
7	lek A	9	lek B
		3	lek B
		2	lek B

W dwóch grupach chorych na pewną chorobę neurologiczną przeprowadzono badania stężenia adrenaliny w surowicy krwi. Zebrane wyniki 24 pacjentów przedstawia poniższa tabela. Zweryfikować hipotezę, że stężenie adrenaliny w obu grupach jest jednakowe.

adrenalina	grupa	adrenalina	grupa
14.34	A	5.33	B
20.33	A	22.5	B
18.79	A	11.74	B
8.22	A	7.39	B
31.5	A	12.34	B
12.08	A	13.22	B
22	A	8.53	B
9.22	A	22.8	B
19.5	A	12.7	B
78.89	A	7.78	B
30.48	A	9.63	B
45.86	A	8.9	B

¹ Dane i niektóre fragmenty tekstu pochodzą z książek:

1) Andrzej Stanisławski, Przystępny kurs statystyki, Tom 2. Modele liniowe i nieliniowe (2007)

2) Andrzej Stanisławski, Modele regresji liniowej. Wydawca: StatSoft Polska (2016)

3. Test t-Studenta dla zmiennych powiązanych

Przeprowadzono badanie tętna u 20 osób przed oraz po krótkim (trwającym 3 min) wysiłku fizycznym. Otrzymane dane z uwzględnieniem płci pokazano poniżej. Czy otrzymane wyniki przeczą hipotezie, że wysiłek wpływa na przyspieszenie tętna? Obliczenia wykonać **ręcznie** stosując odpowiednią statystykę.

Lp.	Płeć	Tętno I	Tętno II
1	K	63	156
2	M	60	132
3	M	74	122
4	M	60	136
5	K	69	148
6	K	75	148
7	K	71	136
8	K	66	158
9	M	76	116
10	M	66	120
11	M	66	126
12	M	76	144
13	K	63	144
14	M	78	126
15	K	83	136
16	K	72	142
17	K	84	138
18	M	72	132
19	M	75	116
20	M	63	138
21	M	63	142
22	M	90	132

4. Analiza wariancji – zadanie 1


Badano czterema metodami czas krzepnięcia osocza krwi u 10 losowo wybranych pacjentów. Chcemy porównać średni czas krzepnięcia dla każdej metody.

Metoda 1	Metoda 2	Metoda 3	Metoda 4
9.10	10.00	10.00	10.90
8.90	10.20	9.90	11.10
8.40	9.80	9.80	12.20
12.80	11.60	12.90	14.40
8.70	9.50	11.20	9.80
9.20	9.20	9.90	12.00
7.60	8.60	8.50	8.50
8.60	10.30	9.80	10.90
8.90	9.40	9.20	10.40
7.90	8.50	8.20	10.00

5. Analiza wariancji – zadanie 2

Dla poniższych danych policzyć **ręcznie** wartość **statystyki F** i zwizualizować wyniki.

wartość	grupa
1	A
4	A
5	A
6	A
3	B
5	B
8	B
7	C
8	C
9	C
10	C



6. Test χ^2 – analiza 1

Badano zależność pomiędzy ilością wypalanych papierosów a wystąpieniem pewnych niekorzystnych zmian w płucach w grupie 1500 osób. Dane, ze względu na ich ilość umieszczono w oddzielnym pliku **Chi2_przykład1.csv**. Należy utworzyć odpowiednią **tabelę wielodziedziłą** i wykonać test χ^2 . Następnie należy **ręcznie** wyznaczyć wartości oczekiwane a następnie wartość statystyki χ^2 oraz zweryfikować hipotezę, czy cechy X oraz Y są niezależne. Podobnie, jak w przypadku testu t-Studenta zwizualizować otrzymany wynik. Narysować rozkład χ^2 dla odpowiedniej ilości stopni swobody i zaznaczyć wartość krytyczną χ^2 oraz wartość χ^2 otrzymaną z danych. Wyliczyć również **miarę siły związku** korzystając z zależności **Yule’a** (tylko dla tablic 2x2), **V-Cramera** oraz **współczynnik kontyngencji Pearsona C**.

7. Test χ^2 – analiza 2

W próbie liczącej 100 mężczyzn w wieku 50-60 lat zbadano częstość występowania choroby wieńcowej i podwyższonego ciśnienia tętniczego. Chcemy ocenić, czy choroba wieńcowa współistnieje z podwyższonymi wartościami ciśnienia tętniczego. Dane, ze względu na ich ilość umieszczono w oddzielnym pliku **Chi2_przykład2.csv**. Zwróćmy uwagę, że w tym przykładzie zachodzą przesłanki do zastosowania tzw. **poprawki Yatesa**.

8. Uwagi na temat miar siły związku.

Statystyka χ^2 sprawdza, czy dwie zmienne są ze sobą powiązane. Jednakże oprócz sprawdzenia, czy pomiędzy zmiennymi zachodzi związek, interesuje nas, jak silne jest to powiązanie. Samej wartości χ^2 jako pomiaru siły związku nie możemy stosować, zależy ona bowiem od liczebności grupy N i rośnie wraz z jej wzrostem. Tym niemniej w oparciu o tę wartość zbudowano szereg miar siły związku. Do najczęściej stosowanych należą:

- współczynnik Φ Yule’a,
- współczynnik V-Cramera,
- współczynnik kontyngencji Pearsona C.


Interpretacja wszystkich tych współczynników jest taka sama:

- jeżeli ma on wartość zero, to cechy X i Y są niezależne,
- im bliższa jedynki jest wartość tych współczynników, tym silniejsze jest powiązanie pomiędzy analizowanymi cechami X i Y.

9. Poniżej podano w „rysunkowej” formie podział testów istotności różnic dla dwóch grup oraz odpowiadające im formuły matematyczne.

III. Test t-Studenta dla zmiennych niepowiązanych

Istnieją różne wersje tego testu, zależne od liczebności grup, wariancji w poszczególnych grupach oraz charakteru rozkładu. Ich przegląd znajdziemy na poniższym rysunku:



Test z - test dla takiego przypadku ma postać

$$z = \frac{m_1 - m_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

gdzie m_i , s_i^2 , n_i to odpowiednio: średnia, wariancja i liczebność i-tej próby. Statystyka z ma standaryzowany rozkład normalny $N(0, 1)$.

Test U - test dla takiego przypadku ma postać

$$U = \frac{m_1 - m_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}},$$

gdzie m_i , n_i , σ_i^2 to odpowiednio: średnia, liczebność i-tej próby oraz znane wariancje populacji. Statystyka U ma standaryzowany rozkład normalny $N(0, 1)$.

Test t - test dla takiego przypadku ma postać

$$t = \frac{m_1 - m_2}{\sqrt{\frac{s_1^2(n_1 - 1) + s_2^2(n_2 - 1)}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

gdzie m_i , s_i , n_i to odpowiednio: średnia, odchylenie standardowe i liczebność i-tej próby. Statystyka T ma rozkład t-Studenta o $n_1 + n_2 - 2$ stopniach swobody.

Test Cochran-Coxa - test ten ma postać

$$C = \frac{m_1 - m_2}{\sqrt{\frac{s_1^2}{n_1 - 1} + \frac{s_2^2}{n_2 - 1}}}$$

gdzie m_i , s_i , n_i to odpowiednio: średnia, odchylenie standardowe i liczebność i-tej próby.

IV. Test t-Studenta dla zmiennych powiązanych (zależnych)

W tym podrozdziale opiszemy metody testowania hipotez, gdy wyniki obserwacji pochodzą z dwóch populacji i są w jakiś sposób zestawione w pary. Test ten stosuje się wówczas, gdy mamy dwie serie wyników dla tych samych elementów (próby powiązane) w różnym czasie (np. przed i po podaniu leku). Dla każdego elementu próby losowej mamy parę liczb x_i i y_i oraz ich różnicę $d_i = x_i - y_i$. Zakładamy, że populacja różnic ma rozkład normalny.

Wówczas zmienna losowa $t = \frac{\bar{d}}{s_d} \sqrt{n}$ (gdzie $\bar{d}$, s_d średnia i odchylenie standardowe różnic d_i) ma rozkład t-Studenta o $n-1$ stopniach swobody.

Takie zestawienie w pary i obliczenie różnic przekazuje nam więcej informacji o różnicy wyników badanych osób, niż informacja, którą otrzymalibyśmy, wykorzystując odrębne dwie grupy (test t-Studenta dla zmiennych niepowiązanych). Poza tym, gdy do badania wykorzystujemy te same osoby, możemy wyeliminować wiele przypadkowej zmienności w ocenach i skoncentrować się na ocenie uzyskanej różnicy między dwoma badaniami.

Algorytm doboru testu istotności różnic

